

操作ログから自動化提案へ — 要約

最終報告書の要約（1ページ）・詳細は `REPORT.md` を参照 リポジトリ: <https://github.com/insaneado/iby>

本要約は英語の最終報告書の翻訳です。原文と相違がある場合は `REPORT.md` を正とします。

対象データ

データセットBから 173分の業務、664件の実行、15セッション、4名の担当者（2026年7月1日）を復元しました。

Step 1 — 業務単位の復元

生ログにはキー入力とクリックしか記録されておらず、「どの業務が進行中か」を示す情報はありません。以下の3点が突破口となりました。

- 案件IDは画面に表示されている。正解データの案件IDの97.8%が画面テキストに出現します（該当する実行の最中に限ると85.7%）。これが当初の手法の出発点になりましたが、同一プロセスの連続実行を最終的に分離しているのは次項の2つのクリックで、案件IDは補完的な区切りとラベル付けに使っています。
- 各業務単位は2つのクリックで挟まれる。対象行の選択クリック（1,780件、99.9%が正解区間内、相対位置の中央値0.13）で開始し、確定ボタン（1,752件、うち1,751件が正解区間内、相対位置0.89）で終了します。両端を用いることで精度が大きく向上しました。
- 待機時間による区切りは機能しない。連続する正解区間の間隔の中央値は0秒です。実測により早期に棄却しました。

精度（データセットA、正解データ2,009件に対して）

指標	ベースライン	本手法
境界F1（±2秒）	0.275	0.700
境界F1（±5秒）	0.365	0.756
WindowDiff（低いほど良い）	0.682	0.195
ラベル一貫性（V値）	0.135	0.719
区間数（正解2,009）	5,236	2,010

担当者単位の交差検証では 0.759（標準偏差0.117）。ただしブラウザ拡張が接続されなかった端末では 0.471 に低下します。

評価指標自体の妥当性も検証しました。同一区間数のランダム分割は0.267であり、本手法との差は+0.489です。ラベルを入れ替えるとV値は0.030に低下します。

Step 2 — 業務分析

ポータルは同一システムを3系統に展開しているため、画面のルート名は業務内容を表しません。実際の業務は、作業中に参照される**規程文書**から特定しました。

最重要の発見: **1つの画面パターンが全業務時間の38.3%**（260件、66.1分）を占め、3系統すべてに存在します。上位2プロセスは、同一画面の異なる展開でした。

同一プロセス内の処理の違いも検証しました。区間内に現れる案件IDから、664件中**578件（87.0%）**について処理した一覧行を特定できます。ポータルが要確認とする行（調整、新規締結・解除）と定常行を、所要時間・キー入力数・規程の参照率で比較したところ、**12の比較のいずれも多重比較の補正後に有意差はありませんでした**。要確認行を人手に残す根拠は、作業量の差ではなくポータル自身の区分です。

Step 3 — 構築した自動化ツール

画面ごとの定義ファイルで駆動する**共通エンジン**を構築し、3系統にまたがる**全12の業務一覧画面**に適用しました。当初の実装は3画面・456行のみを対象としていましたが、これは抽出処理が表の列構成を決め打ちしていたための欠陥でした。画面に表示される表の見出しを読み取る方式に改めたところ、12画面・984行・5種類の表構造が判明し、いずれも1つのエンジンで処理できています。

実測結果（全984行、12画面）

結果	件数	割合
定常処理（定型文で自動化）	821	83%
要確認行（規程の金額基準で自動振分）	37	4%
完全自動化	858	87%
人手が必要	126	13%
失敗	0	0%

1行あたり中央値132ミリ秒。

要確認行を規程で振り分けるのは、その画面の担当者が実際に参照している規程がある場合に限りでした。また、自動化した858行のうち277行は、担当者が大半の実行で手順書や規程を参照する5画面のもので、ツールはその参照を行わずに処理します（主要なリスク参照）。

LLMを実行経路に含めない判断

当初はRAG構成を想定しましたが、実測により棄却しました。

- 応答時間: 決定的処理170ミリ秒に対し、モデル23,310ミリ秒（**137倍**）
- 5回中2回がタイムアウト
- 出力品質: 規程のファイル名を返すのみ

さらに根本的な理由として、規程の内容は判断ではなく**数値基準**でした。

第2条（承認権限）1回あたり5万円未満：部門長承認。5万円以上：役員承認。10万円以上：社長承認。

金額による承認者の振分は算術処理であり、コードで実装すべきものです。正確、即時、無償で、規程と1行ずつ照合可能であり、承認者を誤って生成することはありません。

モデルに残る役割は1つだけで、オフラインです。規程文書から規則表を「提案」し、人間が確認したうえで適用する想定ですが、数値基準を持つ規程3件はすべてモデルなしで解析できたため、実装はしていません。ツールは既定でモデルを呼び出さず、実行時は完全に決定的です。

残る手作業と現実的な効果

- 984行中126行（13%） — ポータルが要確認とし、担当者が参照している規程では判断できない行です。内訳は、新規締結・解除の契約43行、担当者が規程ではなく取引先一覧で確認する請求書の調整40行、規程の参照が見られない在庫調整43行（うち26行は金額欄が空欄）です。承認規則を顧客に確認するまでは、ここが正しい境界です。
- 規程13件のうち10件は数値基準のない手順書形式で、ツールはこれらを読み込みません。これらが参照される画面でも、定常行は参照なしで自動処理しています。その確認を人が引き続き行うべきかは未解決です（主要なリスク参照）。
- 例外処理はログに記録がなく、設計できていません。

本記録は待機時間が圧縮されたテスト環境のものであるため、削減時間の絶対値は算出しません。実証できるのは相対値のみです。すなわち、観測されたポータル業務（全12画面）を対象とし、その範囲内で87%を自動処理しました。

主要なリスク（すべて実測に基づく）

リスク	根拠
テレメトリ欠損による精度低下	端末1台でL3イベントが0件、精度0.471
模擬環境と本番環境の差異	セッション管理・サーバ検証・ページングは未観測
部門間での手法の非転用性	本プロジェクト中に3件の転用失敗を実測
共有アカウントでの実行	3系統とも担当者間で共有、監査証跡なし
定型の「確認済」は確認そのものではない	5画面では担当者が大半の実行で手順書・規程を参照するが、ツールは参照せずに277行を処理
規程改訂による基準の陳腐化	基準は文書から抽出、再抽出と人間承認が必要

次に行うべきこと

1. 本番相当環境での実行検証
2. ポータル背後のAPI有無の確認（存在すれば本ツールの大半は不要）
3. 端末別のL3カバレッジ監視
4. 人手に残る126行（契約43行・請求書調整40行・在庫調整43行）への対応。請求書と在庫の調整は、まず承認規則を顧客に確認します。契約は画面の追加ではなく、手順に従った判断の自動化が必要です。